ACL/ARR 极严格模拟审稿报告：MIST v6

REPORT CONTENTS / 阅读导航

1. 执行摘要与模拟评分
2. v5→v6 实质改动审计（逐项核验）
3. 主要问题（Major Weaknesses，按录用影响排序）
4. 逐公式、接口和评测逻辑核验
5. 逐节、逐图与逐表复核（针对 v6 的 page-accurate 评论）
6. 次要与工程可复现问题（25 项可执行意见）
7. TeX 源文件专项审计：这次实际能验证什么？
8. 必要补充实验与重写优先级：按投入产出排序
9. 我希望在 rebuttal 中得到的 18 个明确答复
10. 作者应保留的优点（不能因为严苛审稿而忽视）
11. 给 Area Chair 的精简判断与条件式结论

Appendix A — Ready-to-adapt English ACL/ARR-style review

Appendix B — 文件和证据完整性清单

论文：Who Said What, in Their Own Voice: Diarizer-Conditioned Speaker-Attributed Simultaneous Meeting Translation with Voice-Prompted Speech
版本材料：`gstar_v6.pdf`（17 页，含附录）与 `gs_v6.tex`（60 行、主入口）
审稿日期：2026-10-31
参考旧稿：`gs_v5.pdf` / `gs_v5.tex`（仅用于核对本版修改是否实质完成）
立场：扮演苛刻的 ACL/ARR 方法与实验审稿人；不是 ACL 官方结论，不代表模型复现实验结果。

> **核心结论：当前 v6 文稿属于“新增了正确的评测方案，却尚未展示相应结果”的未闭环版本。** 新版显著改善了标题定位、对因果性的描述、测试覆盖度披露，并增加了完整会议运行、强基线和严谨统计的设计。但这些新内容仍停留在方法和实验设置叙述，现有主要结果表与附录没有对应更新。相反，Limitations 仍明确称完整会议尚未被端到端评分。若这一 PDF 就是最终投稿文件，我倾向 **Weak Reject（2/5；信心 4/5）**；这并不意味着方案不值得发表，而是证据链在最关键处尚未闭合。**这份评价以提交文件的实际内容为准，而不是推测作者在本地是否已经有新的实验结果。**

定位格式：`[v6 p.5, L406–434, §3.9]` 表示 v6 PDF 页码和印刷于页边的论文行号；`Eq.(n)` / `Table n` 分别是论文自己的公式和表。TeX 使用 `[gs_v6.tex:Lxx]`。**严重度**：P0 = 影响核心结论/投稿完整性；P1 = 决定说服力的重要实证缺口；P2 = 修订和复现问题。**论证状态**：`[已确认]` 仅表示附件中可直接核实；`[证据缺失]` 表示论文没有展示足以验证的资料；`[潜在风险]` 表示需要额外实验判定，不能认定系统必然存在该缺陷。

1. 执行摘要与模拟评分

1.1 评审判断

模拟 overall：Weak Reject（2/5）；confidence：4/5。 如果作者把 v6 所承诺的完整会议实验、真实听众端延迟、增强基线、跨种子结果以及新统计分析真实补齐，并修复所有跨章节矛盾，这篇工作可上升为 borderline 乃至可接受的系统研究。**但仅改写正文而没有填入相应结果，不能提高证据强度。**

维度	模拟分数	简要判据
任务重要性 / Impact	4/5	会议重叠、稳定身份与可辨认目标语音是有价值的实际问题。

维度	模拟分数	简要判据
系统创新 / Novelty	3/5	speaker interleaving 源自 G-STAR；真正新增是译文结构化、deadline commit、voice-prompted TTS 与会议场景的集成。
技术合理性 / Soundness	2.5/5	关键算法有形式化；在线输入、真实延迟与端点机制的证据未落实。
实验质量 / Evidence	2/5	旧窗口实验可靠性较强，但新增强基线和完整会议测量未见报告；真实 Mandarin 无明显优势。
写作与完整性 / Presentation	2/5	新 title 更准确，新增局限披露值得肯定；多处 `§??` 和章节自相矛盾属于提交级错误。
可复核性 / Reproducibility	2/5	一部分超参数足够细；仅给出主 `.tex`，不含所引用的 `sections/`、`generated/` 和生成脚本，不能重编或审计表格。

最重要的审稿决定条件：

1. **完整会议是否真的跑了？** 新 §3.9 给出了 online-window 推理规则，但没有完整会议的 tcpBLEU、遗漏/插入/重复、语音实际延迟、队列积压、显存与计算耗时；Limitations 仍说没有完整会议端到端评分。[v6 pp.5–7, L406–434、L579–598；p.10, L760–773]
2. **最强比较是否公平？** v6 终于列出了 turn-trained/oracle/contextual cascades、post-hoc relabelling、prefix-trained LA2、fixed lag、streaming cascade，但 Table 1 和 7–15 仍没有这些新对照分数。[v6 p.7, L525–566；pp.8、15–17]
3. **统计声称与表格是否一致？** 正文说 two-sided permutation/Holm/leave-one-meeting-out/extra seeds；Appendix F 和 Table 9 仍是旧的单侧 bootstrap 计数，且个别 p 值与 95% 双侧 CI 不吻合。[v6 p.7, L608–617；p.13, L1067–1074；p.15, Table 9]

1.2 可接受的贡献边界

作者确实建立了一个将 **冻结的 Streaming Sortformer 说话人活动流、冻结的 Qwen3-Omni 声学表示**和**可微 speaker projector + Thinker LoRA**结合的系统。解码器一口气预测 `speaker / source start / target translation / source end / wait`，再由独立 UniSS Talker 使用因果获得的 speaker prompt 生成声音。它在 AMI 的**参考切分窗口**上取得重要的归属翻译增益。这是有价值的 diarizer-conditioned speaker-attributed translation with learned commit and external TTS；不是一个从输入声波到输出声波端到端联合训练的单一模型。[v6 pp.3–5, Fig.1、Eqs.(2)–(18)]

1.3 四个已经由 v6 数字确认的结论

- AMI En→Zh、Zh→En 的**离线文本 cpBLEU_sess** 分别是 **42.81 vs 36.29（+6.52）**、**25.86 vs 22.36（+3.50）**，比较对象是论文的 same-data cascade；这是窗口级优势，不是完整会议在线结果。[v6 p.8, Table 1]
- AMI En→Zh 的 **simultaneous text** 是 **42.63 @ 2.32s LAAL**，相比 offline MIST + LA2 的 **31.64 @ 2.37s**，约 **+10.99**；由于 LA2 基线未进行对应的 prefix training，该差额不等于 deadline policy 的独立因果效应。[v6 pp.8–9, Table 1, L650–675]
- AMI Zh→En 同步文本是 **24.30 @ 2.93s**，而 offline MIST + LA2 是 **24.81 @ 2.50s**：**没有质量优势，且延迟更大**。[v6 p.8, Table 1]
- 在真实 Mandarin AliMeeting 上，离线 MIST **14.90**，same-data cascade **15.25**；同步 MIST **12.97 @ 3.09s**，LA2 **12.10 @ 2.84s**。这些结果**不支持“在真实 Mandarin 上显著优于级联或 LA2”**。[v6 p.9, Table 2、L685–700]

2. v5→v6 实质改动审计（逐项核验）

与上一版比较，本版并非原样提交：对多项最重要的审稿意见采取了方向正确的措施。问题是“**新计划/新陈述**”是否被“**新数据/新定义**”验证。

改动	v6 证据	审稿判断
标题从“End-to-End S2ST”改为“Diarizer-Conditioned … with Voice-Prompted Speech”	p.1 标题	**已修复一部分措辞过强问题**，比 v5 诚实。
Fig.1 说明冻结 diarizer、encoder、Talker，梯度只到 projector / new rows / LoRA	p.3, Fig.1 caption L161–166	**已改善**模型边界；仍需避免结论里“一模型”过度概括。
§3.3 明确 streaming Sortformer 的 0.72s chunk、0.32s right context、缓存	p.3 L200–218	**描述增加**；“数值验证”仍指向 `§??`, `Appendix ??`，附件里没有结果。
§3.5 新增 `α=β` 的测量，报告 En→Zh 2.6% 零时长 segment	p.4 L272–276	**发现问题但未修复**：时间标注指标与 Eq.(1) 仍有冲突。
§3.7 明确每次 read 真正使用 `x≤t` 重新编码，不输入整窗遮蔽向量	p.5 L339–349	**因果性叙述更清楚**；需实验核验 cache/token 稳定性、实时算量。
新增 §3.9：diarizer 驱动窗口、20s 截断、跨窗口单通道积压、计算时间	pp.5–6 L406–434	**关键方法补强，但结果缺席**；旧 Limitations 仍说未评测。
披露 AMI 英中参考窗口仅覆盖 45.6% speech、35.6% overlap，AliMeeting 仅 63.0% speech	p.6 L449–459、L481–497	**重要且诚实的补充**；反而凸显旧结果的选样偏差。
披露 En→Zh 和 Zh→En 共享 AMI 原始 16 个测试会议	p.6 L478–480	**积极修正**：不能误以为双向是相互独立语料。
新增 turn-trained、oracle-turn、contextual cascades	p.7 L525–541	**仅列名称/构造，未找到分数**；公平性尚未被实验证实。
新增 speaker stream 的 post-hoc relabelling 对照	p.7 L541–547	**关键消融思路正确**；缺结果，不能证明 interleaving 优于后处理。
新增 LA2-on-Simul、fixed-lag、streaming cascade	p.7 L548–559	**关键在线基线方向正确**；Table 1/6/9 均无相应分数。
规定整会议 tcpBLEU、带计算的 listener-side lag、segment-level 归属指标	p.7 L567–608	**只有定义性文字**；新度量未给公式、对照表、可复现实现。
说增加两颗 En→Zh seed，采用 permutation / Holm / leave-one-meeting-out	p.7 L520–523、L608–617	**文本承诺未兑现**；旧 Table 9 和 Limitations 与之冲突。
增加 TitaNet 和 WavLM 两种 speaker verification	p.7 L603–607	**方法文字新增**，Table 3 仍只明确列 WavLM，没有 TitaNet 分项。
文末仍保留旧 Limitations：“未测整会议”“未比 prefix-trained LA2”“单 seed”“计算无关”	p.10 L760–789	**实质性内部矛盾**，不是可忽略的引用错误。
PDF 出现 `§??`、`Appendix ??` 等未决定位	p.3 L218；p.6 L459；p.7 L589	**已确认的成稿质量问题**。

结论：v6 在研究设计层面朝正确方向前进；**在本次上传的 PDF 层面，所需要的验证还没有落地。** 以下主要问题按 v6 文件实际状态重新评级，而非把 v5 批评无差别复制过来。

3. 主要问题（Major Weaknesses，按录用影响排序）

M01 [P0 / 已确认] 新增主张、基线、指标和结论之间出现系统性的“结果缺席”

证据链：§3.9 定义整会议在线运行 [p.5–6, L406–434]；§4 增加 turn-trained/oracle/contextual/post-hoc 和多个在线基线 [p.7, L525–566]；Metrics 定义 tcpBLEU、整会议听众端 lag、双 speaker-verification [p.7, L567–608]；Statistics 说两侧检验、Holm 和 extra seeds [p.7, L608–617]。但实际 Table 1–15 仍只覆盖原有的参考窗口评测、旧语音客观分数及旧的 bootstrap；并无“新完整会议汇总表/图”、新基线分数、额外 seed 平均/方差、TitaNet 结果、tcpBLEU 数值或尾部实际延迟直方图。尤其 Conclusion 完全未讨论任何新增整会议测量。[pp.8–9, L736–743]

为何关键：读者不应通过作者“计划测量/写了指标定义”的文字来推定其已完成了实验。新增这些内容还改变了论文的论证结构：如果整会议实验表现不佳，系统最强应用结论会进一步缩小；如果表现好，当前稿却没有给出可以复核的数字。

必须补：至少一张完整会议文本+语音主表；一张公平基线对照表；一张统计与跨种子表；一段关于真实 Mandarin 结果的限制性讨论。每个新 baseline 必须在一张明确的表中有实际指标，或者删去“已运行”暗示、标记为拟议未来工作。不要把所有新增实验藏在仅口头引用的附录。

建议作者回答：这些数值是尚未跑完、跑完但 `make_tables_v6.py` 未写入 PDF，还是意图另附 supplement？当前附件不允许审稿人区分。

M02 [P0 / 已确认 + 证据缺失] §3.9 是完整会议的算法草图，不是完整会议评估；Limitations 直接否定新主张

证据：§3.9 规定 diarizer>0.5 启动窗口，连续 1s 无活动关闭，最多 20s，前后 padding，decoder 在窗口边界重置，而 speaker slots 延续；音频播放队列跨窗口累计，计算时间计入 commit。[v6 pp.5–6, L412–434]。但是 §4 的 `the whole-meeting evaluation (§??)` 没有真实定位 [p.6, L458–459]；Metrics 的 tcpBLEU、listener-side lag 无结果 [p.7]；Limitations 原文仍陈述 `we have not scored whole meetings end to end`，以及 `listener-side lag is measured within windows` [p.10, L760–773]。

评价：这是可直接证实的**文本与证据矛盾**，不能被视为“作者没有实现整会议系统”的直接证明。算法写出来不等于做了测试。与原来的 reference-utterance windows 不同，整会议覆盖全部听到的语音，并涉及未标注/未过滤的 backchannel、连续超过 20s 的流和长时间 TTS backlog。没有这部分对照就无法评价核心应用是否成立。

最小可接受实验：选定 AMI 官方完整 16 个测试 meeting + AliMeeting 完整 20 个 meeting，按时间推进一次，不使用参考分割决定窗口或 `<eos>`。明确音频重放条件、silence threshold、speaker cache、每次 read 的 $x \leqslant t$、每次 TTS 能否及时播完；报告 full-meeting `tcpBLEU`、归属错率、coverage、遗漏/重译、输出时长比、speaker identity stability、文本首字及音频首包/播放完成 lag、p50/p90/p95 backlog。务必与相同 online windowing 和同一个 Talker 的强基线比较。

附加安全检查：对 20s 硬切时正在说话的 utterance 是否被截断、最终未读 flush 的构造、0.2s 前置填充需要多少历史缓存、0.3s 尾部填充如何延迟关闭，都需可执行伪代码。仅“窗口已被某规则切出”并不能让这些时间戳在线可用。

M03 [P0 / 证据缺失] “严格因果”论证比 v5 进步，但新增的数值校验是空引用

证据：在 §3.3，作者说 Sortformer 以 0.72s chunk、0.32s 右上下文加 speaker cache 的流模式运行，已定稿帧不回改、无 session-global statistic，并说数值验证 prefix run 与 streaming run 的帧一致；然而引用显示 `this numerically (§??, Appendix ??)` [v6 p.3, L200–218]。§3.7 又明确 encoder 接收前缀 $x \leqslant t_r$，而不是将完整音频 embedding 后遮蔽，并说明 Eq.(9) 只用于训练目标与评测。[p.5 L339–349]

肯定之处：作者明确澄清 Eq.(9) 是离线监督标签对齐，并不意味着把参考说话人标签喂给测试模型；前缀 encoder 的文字说明也排除了 v5 的一种可能错误实现。**不能仅凭早期 Eq.(3) 写成 `P=Diar(x)` 就断言已经泄漏。**

仍需验证：给 `max|P_offline_streaming_prefix(t)-P_true_online_prefix(t)|`、mean absolute deviation、speaker slot ID drift / reorder count、有效帧一致比（各说话人、长会议和 overlap 分层）；另给 `Enc(x≤t)` 与不断追加音频时既有 token 是否变化及 padding/receptive field；附公开的 `read→finalize→project→decode` trace。无数值验证却声称“we verify numerically”是不完整的事实主张。

M04 [P0 / 已确认] 新加强的 cascades 和同步基线被列举，却没有被真正用于结论比较

证据：新列举三种翻译端级联增强：turn-trained、reference-turn/oracle、±2s context；以及后处理同 posterior 的 post-hoc labelling [v6 p.7, L525–547]。同步端列举 LA2 on MIST-Simul、MIST-Simul fixed lag（1或2s）、low-latency streaming cascade [L548–559]。但 Table 1 只保留 Qwen prompted / original cascade / same-data cascade / MIST stream ablation / MIST offline / MIST LA2 / MIST-Simul / oracle activity，Table 6、9 也未纳入新基线。[v6 pp.8、14–15]

为什么不能用“新增了基线描述”解决公平性疑问：原级联按 diarizer threshold 切 turn，只给短音频；MIST 看完整多说话人窗口。把 multi-speaker 窗口上训练的 translator 拿去切碎的 turn 上推理也引入输入长度/上下文分布失配。LA2 对照没见过任何不完整输入，作者自己说它产生过度生成（1.18×参考长度）[p.8, L650–675]。新设计中的 turn-trained/prefix-trained 恰好可以判断旧收益是否来自对照过弱，但没有分数就没有答案。

最小主表：对于 En→Zh、Zh→En、AliMeeting，在同一覆盖范围/相同在线切窗/相同 Talker/相同推理预算下，报告 MIST vs. standard cascade、turn-trained、contextual、oracle-turn、post-hoc relabel、LA2-offline、LA2-on-prefix-trained、fixed-lag、streaming cascade，并标注哪个 baseline 具备 oracle 信息（oracle 不应被当作现实可部署系统）。结论按“相对最强非 oracle baseline”重写。

M05 [P0 / 已确认] 双侧统计/多重校正的陈述与 Table 9、Appendix F 的算法定义互相冲突

原文：§4 宣称使用 meeting paired bootstrap、permutation test、leave-one-meeting-out，`p values are two-sided`、`pre-registered tests ... Holm-corrected` [v6 p.7, L608–617]。Appendix F 却仍说 session speaker matching 在全测试集上固定，按 window/meeting 做 bootstrap [p.13, L1067–1074]；Table 9 caption 则把 p 定义成 `the share of resamples in which the first system is not better` [p.15, Table 9]。这个定义是**单侧尾部比例**，不是普通的 two-sided p，更不是已展示的 Holm-adjusted permutation p。

可核查数值实例：Table 9 中 En→Zh `MIST-Simul-M, Δ=2` 相比 `MIST-Simul, Δ=2`，window 95% CI 为 **[-0.10, 7.60]** 却列 p=**0.043**，meeting CI **[-0.06, 6.90]** 却列 p=**0.034**。Zh→En 语音 `MIST-Simul vs MIST+LA2`，window CI **[-0.09, 4.09]** 却列 p=**0.030**，meeting CI **[-0.35, 4.74]** 却列 p=**0.050**。这**可能**是单侧 tail p 与双侧 95% CI 混排造成的，并非一定是算错数据；但它**不能支持论文统一宣称的“双侧、校正后”检验逻辑**。此外 1,000 次 resamples 的 `p=0.000` 应表达为 `p<0.001`（或显式说明估计方式）。

必须纠正：明确四类输出：`effect size`、meeting-cluster 95% CI、two-sided meeting permutation p、Holm-adjusted p；所有主张使用同一侧性约定并区分探索性比较。列出预注册材料（日期、对比家族、终点，若确有）或取消“pre-registered”一词；报告 leave-one-meeting-out 的最小/最大差值及最敏感的 meeting；不要把 window bootstrap 当作对会议独立性的主显著性证据。若采用重复抽样后重新匹配 slot，给伪代码；若每 meeting 匹配固定等价，说明条件。

M06 [P0 / 已确认] “多 seed 已训练”缺结果，同时 Limitations 仍声称只有一个 seed

证据：§4 `for En→Zh MIST-Simul we also trained two more seeds (§5.2)` [v6 p.7, L520–523]，但 §5.2 只有旧的 single-run En→Zh 与 Zh→En 曲线和 text LAAL 论述，没有均值、方差、置信区间或独立 seed 表。[p.8–9, §5.2、Fig.2/Table 6]。Limitations 继续称 `Each model was trained once, with a single seed` [p.10, L784–787]。

分析：文本两处并不能同时按字面成立。因为作者明确指明“额外两颗 seed”，最合理的修订是给出至少三个 seed 的个体分数、均值±标准差、延迟与失败率，并把 Limitations 改为“仅 En→Zh 主 Simul 有三个 seeds，其余一个”。抽样窗口 CI **不能**替代训练随机性。

M07 [P0 / 证据缺失] tcpBLEU、segment-level attribution 和完整听众端语音延迟被提出，却缺乏可复核定义与结果

证据：§4 声称 cpBLEU 对时间不敏感，新增 `tcpBLEU`：输出段被分配给“同 speaker、相差小于1s合并的参考 utterance unit”，与 ±2s collar 重叠才匹配；还提及 segment-level precision/recall/omission/onset/offset in `Appendix ??` [v6 p.7, L567–599]。但真实的 Appendix C 仍只有 `cpBLEU`、DER、LAAL 的旧公式，完全没有 tcpBLEU 算法定义/评分结果 [p.12–13, L1031–1064]。正文各表和附录均未列出 tcpBLEU 或整会议 listener-lag。

严重性：`tcpBLEU` 如何将 翻译语义、speaker permutation、时间一致性 合在同一个 corpus BLEU，决定该新指标是否可信。歧义包括：一个输出跨多个 reference units；两个输出同属一个 unit；reference unit 在 overlap 时属于不同 speaker；没有有效时间锚的插入；2s collar 过宽对短 backchannel 会否过度宽容；匹配顺序是否在整个 meeting 固定；语音 ASR errors 怎么落到 speaker/time 单元。

必须提供：完整算法/伪代码、一个带 2 个说话人与三处重叠的 toy example、单元集统计、对 0s/0.5s/1s/2s collar 的敏感性、cpBLEU 与 tcpBLEU 的差异、该指标与人工错误标注的相关性。音频延迟至少分别报告 `text commit`、`TTS first-sample ready`、`playback onset`、`playback completion`，并给 p50/p90/p95 与重叠率分层。

M08 [P1 / 已确认] 参考窗口的选样偏差比 v5 暴露得更清楚，对核心结果的外推影响巨大

新增事实：En→Zh 的 2,375 个测试参考窗口只有 3.9h；v6 现承认这些窗口只包含测试 meetings **45.6% 的讲话时长**、**51.2% 的 ≤1s utterances**、更只有 **35.6% 的重叠讲话时长**；窗口组会因跨界、超过 20s 或译文/合成自动审核未通过而整体丢弃 [v6 p.6, L436–459]。Zh→En revoiced 测试窗覆盖 **88.0%** 对应 speech，AliMeeting 只覆盖 **63.0%** [p.6 L462–497]。

不应误读：35.0% 测试窗口包含多人，不等于“覆盖 35.0% 的原始 overlap 时长”。v6 的覆盖披露恰恰说明，原来靠窗口内 multi-speaker 比例无法证明最难的 overlap 样本被保留。AliMeeting 的 10.8h 总时长与 7.5h 窗口音频时长也不完全等同 speech 时长，因此应使用作者明确给出的 speech coverage 而不是自行以两者相除代替。

建议：完整会议实验必须评估保留/被过滤两组各自的多说话人召回、重叠秒数、≤0.5/1s backchannels、无单独说话片段、≥20s 连续对话；列一个 “raw meetings→reference windows→kept speech→kept overlap→kept short utterances” 漏斗表。仅在保留样本上 +6.52/3.50 不能证明未保留区域也同等受益。

M09 [P1 / 已确认] 在真实 Mandarin 的重要外推实验上，离线质量与 speaker 指标没有优于 cascade

证据：AliMeeting，offline MIST vs same-data cascade：cpBLEU **14.90 vs 15.25**，speaker-count **91.9% vs 92.5%**，DER **14.7% vs 13.1%** [v6 p.9, Table 2]。同数据 domain 外 test 上无显著赢面；Simul 为 **12.97 vs 12.10**，却要 **3.09s vs 2.84s text LAAL**，差值不显著 [p.9, L685–700]。此外还只用机器 MT 将 AliMeeting 的人工普通话转写生成 English reference，未做人类译文质量审查。[p.6, L481–503；p.10, L744–759]

重要区分：作者已对这一弱点比较坦诚；问题是论文主题与任务设定仍需要真实多说话人会议上的正面实证。合成中文源来自同一 AMI meeting 的重配音/语速修正，原语言内容和说话人结构并非新真实采样。[v6 p.6 L462–480、Appendix I]

补救优先级：至少补真实 Mandarin 连续会议全流程，并分 single/multi/overlap/short-turn 和会议时长给误差；可增若干人工翻译质量审查集，避免仅用 MT reference 容易影响句子级排序。不要把对 AMI 的双向提升描述成跨语料、跨语言条件独立复制。

M10 [P1 / 证据缺失] interleaving 的独立贡献仍不能仅由“去掉 speaker stream”证明

现有消融：v6 Table 1 去掉 speaker stream 后 En→Zh `cpBLEU_win=42.32`，MIST `42.97`，然而 `cpBLEU_sess` 从 42.81 降到 21.17：主要损失是**跨窗口 slot-label 对应关系**，不必然表明神经网络在单窗口说话人分离上更好。[v6 p.15, Table 7；p.9 L717–728]。

新设计是对的：v6 添加 post-hoc relabelling，使用与 MIST 一样的 diarizer posterior，在译后给无 stream 模型分配固定 slot [p.7, L541–547]。这是区分“需要持久身份源”与“必须在解码期间 interleave”最有价值的对照之一。但**没有任何 post-hoc 对照分数**，所以引言“speaker stream 是维持 identity 的关键”仍只能归因到提供了外部 identity，不够解释具体融合结构的优势。

补实验：在相同长期 identity 信息和数据上比较 `interleave K=5`、speaker posterior 后标注、speaker-tag at prefix、additive fusion、binary activity、time-varying speaker embedding；报告 `cpBLEU_sess`、`cpBLEU_win`、DER、overlap errors、时序偏差、推理 FLOPs 和 slot 重新进入后正确率。

M11 [P1 / 证据缺失] learned deadline policy 的改进归因尚未被新的同等训练对照检验

证据：当前强 En→Zh `+10.99` 仍是 trained Simul 对比 offline+LA2 [v6 p.8 Table 1]。作者新声称会在 prefix-trained MIST-Simul 上再跑 LA2/fixed-lag [p.7 L548–558]，还说 stable-prefix 与 deadline 实验在“exactly the same windows and reads”上各训练 3,000 steps [p.7 L561–566]；实际 Appendix J 仍说 stable-prefix 在 **8,000** training windows、混合间隔 `{0.5,1,1,2}` 上继续训练，而 Table 15 仍把 full-data MIST-Simul 的 `42.63` 与 stable-prefix 的 `32.73` 对比。[p.14 L1126–1144；p.17 Table 15]。**这段文字与附录难以同时理解为严格匹配的数据实验。**

为什么重要：+9.90 的 deadline-vs-stable-prefix 差值可能混有训练数据量、read interval 配置、prefix exposure 或训练 row 分布差异。即便作者真的做了新的 matched-data 实验，现有 Table 15 也没有写出其 checkpoint、读间隔和原始差值。

最低补强：清楚区分 `full-data deadline`、`8k-window deadline`、`8k-window stable-prefix`；匹配所有 read interval、训练步数、batch tokens、checkpoint 初始化、数据构造与 seed；将完整 latency–quality Pareto 曲线及推理成本画在同一图。Zh→En 当前 24.30 @2.93s 对比 stable-prefix 24.07 @2.35s，**0.23 质量差异很小但更慢**，需要如实说明。

M12 [P1 / 已确认] 关键的多说话人 speaker-count 结果不一定比 cascade 好；正文只强调总体指标

具体发现：En→Zh 总窗口 speaker-count accuracy，MIST offline **89.5%**，same-data cascade **88.2%**；正文强调前者更好。[v6 p.8, Table 1；L640–646]。然而在真正关注的 **multi-speaker windows** 中，Table 10 显示 MIST offline 只有 **72.8%**，而 same-data cascade **78.7%**，**低 5.9 个百分点**。[v6 p.16, Table 10]。与此同时 multi-speaker cpBLEU 则 **39.39 vs 31.97**，翻译更好。两种结果完全可以同时成立，但它们表达的是不同机制：MIST 在重叠语音“辨认有几人”方面不一定领先，即使它在生成的归属文本质量上更有优势。

严苛 reviewer 会问：将总体 speaker-count 的微弱领先用于支撑 “finds the right number of speakers more often” 会不会掩盖最困难子集的下降？在 En→Zh 的高重叠区是 `under-count`、`over-count`、短 backchannel 丢失还是 threshold/time-stamp 的 DER 惩罚造成？

建议：主文同时列 single/multi 各自 speaker-count；报告以 utterance duration/overlap duration 分层的 missing-second-speaker recall；把 “better on overall windows” 改成精确措辞；把 Table 10 由附录提至主文或至少主动讨论。

M13 [P1 / 已确认 + 证据缺失] 首次 speaker voice prompt 的因果可得性与人类可辨认性没有闭环

证据：Eq.(17) 使用 solo frames 且至少 0.4s、最多 8s；若 slot 从未 solo，则改用自身 segments [v6 p.5, L383–405]。v6 增加 WavLM 与 TitaNet 双验证器的文本描述，但 Table 3 仍只有一列 SIM/WavLM 与 `V-conf` [p.7 L602–607；p.9 Table 3]。没有人类辨认或 MOS。Zh→En MIST offline 的 WavLM SIM **0.69** 低于 cascade **0.73**，V-conf **60.2%** 高于 **47.2%**；作者自己仅为 En→Zh 声音归属做正面主张。[p.9 L701–716]

重要的时间问题：如果第一段输入只有一个极短的 overlapping backchannel，`first commit` 时可能没有足够 solo 语音做 prompt；用“自身 segments”又可能含有其他人的声音。某个 speaker 首次出现后是否必须推迟翻译语音，直到有一定长度的注册声纹？如果无需等待，默认/跨语种提示音色如何定义？这些不只是 TTS 细节，而是 `who said what in their own voice` 的核心。

需要：报告每个 speaker 首次承诺前可获得 prompt 的比例、长度分布、混音污染、回退和失败率；WavLM/TitaNet 分开的 speaker ID accuracy 与 CI；5–10 秒片段的盲测 ABX/identification、自然度、听懂率以及真实会议完整时间线。限制性表达应是“speaker-conditioned synthesis on selected AMI experiments”，而非全方向全场景的声音保真证明。

M14 [P1 / 潜在风险] 单声道翻译播放队列可能积压、改变谁先说话以及“实时”体验

证据：Eq.(18) 定义输出片段的开始时间 $\pi_n=\max(\zeta_n,\ \pi_{(n-1)}+D_{(n-1)}+g\cdot 1[k_n\neq k_{(n-1)}])$ [v6 p.5, L400–405]；§3.9 特别强调 backlog 跨窗口延续 [p.6, L429–434]。这是新版本值得肯定的意识，但**没有任一条实际长会议队列曲线**。

问题：两位参会者同时讲话，目标译声不能在一个声道同时播放；即使所有文本在 2s 左右 commit，只要目标语音总长度持续大于源流可用时间，播放积压就会增长。Eq.(18) 可能为了不重叠而把原本重叠的“同意/否定”播成先后发言，改变语用含义；短 backchannel 的时间位置与声纹是最脆弱处。

建议：输出 `arrival rate (translated speech seconds / source wall-clock seconds)`、queue utilization、queue length、peak backlog、p95 completion lag、会话末尾清空队列所需的额外时间。给实际不少于 15–30 分钟的在线完整会议录屏/对齐时间轴；对比允许压缩语速、chunk merging、略微变速、跳过重复与双声道提示等策略。严禁把 `text-LAAL≈2s` 直接替代真实听到的话的延迟。

M15 [P1 / 已确认] 时间戳量化导致零时长输出（2.6%）并被 DER 排除，违反任务的正时长要求

证据：Eq.(1) 定义 $a_n < b_n$ [v6 p.2 L160–174]；Eq.(8) 以 80ms bin 分别向下取整并裁切到 $[0,250]$，v6 新增声明 En→Zh MIST 的 **2.6%** 输出段满足 $\alpha_n=\beta_n$，保留译文但在 DER 中计为零时长 [p.4, L260–276]。

技术含义：对短 “yes/no/嗯”、重叠与句尾片段，输出并没有真正有效的源时间跨度，却能进入 cpBLEU 的翻译文本。DER 计算忽略这类段的 activity，可能通过 miss/false-alarm 等其他项体现，却不会把“译文时间定位正确”当作成功。2.6% 不应该仅作为补注而不修复；该比例是 **En→Zh 特定模型输出段**，不能自行外推到全部方向或系统。

可行修复：输出后约束 $\beta\geq\alpha+1$（需检查是否引入越界/假增量），或以四舍五入/软边界建模，使每段最短一个 80ms bin；报告修复前后 DER、time-F1、onset/offset MAE、短重叠段得分。对于 20s 边界处被裁切产生的零长度也应另列比例。

M16 [P1 / 潜在风险] 在线窗口的起止推断与训练目标的语义切分分布并不一致

证据：reference windows 由人工 utterance “overlap/touch”形成，超过 20s 的 group 被丢弃且必须通过 MT/TTS 过滤 [v6 p.6 L436–459]；在线 §3.9 则用 diarizer >0.5、1s silence 与硬上限 20s 自动分割，不过滤任何语音 [p.5–6, L412–420]。训练虽包含 6,988 个 diarizer-defined windows，但数量/质量构造不同 [p.6 L459–461；Appendix A p.12, L1012–1020]。

风险：20s 可将源句在动词/否定/人名处截断；自动窗口在声学静默段结束但句法语义未结束；已有翻译 chunk 仍可能处于“还没听到关键源词”的状态。在线系统若每窗重启 Thinker，语言理解上下文随窗口切断，虽然 speaker cache 继续运行；这对跨窗指代、笑声/重叠否定和长句有系统性影响。

必测：按 `window ended by 1s silence` 与 `window forced at 20s` 分组的错误，窗口边界前后 2s 的词漏/重复、跨窗指代与 speaker-change consistency。给在线窗口长度和截断比例，训练、测试同规则的 sensitivity；解释如何处理 `T` 未读前尚未到 deadline 的 chunk，以及延迟检测 close 对“最后一次 read”时间的作用。

M17 [P1 / 证据缺失] 实时计算负担未知，重算完整声学前缀可能使“low latency”失去意义

证据：在 Eq.(13) 每次 read 解码直到 `<wait>`，§3.7 明确 “encoder is run on the audio prefix itself” [v6 p.5, L334–349]；完整会议 speaker cache 贯穿，decoder 则每窗口重启 [p.6 L425–434]。文中只给训练设备（8×H200）、部分 batch size，文本 LAAL 明确“不含 computation” [p.7 L504–523、p.8 caption]。

需要区分：理论上避免 LA2 的重复解码与真实运行速度是两回事。每秒对增长的最长 20s 前缀重复做 audio encoding + Thinker prefill + greedy decode，计算可能较高；模型是否对既有 acoustic tokens 实施 cache 复用，是否因音频前缀编码变化而不得不重新 prefill，论文未明确。声纹提取、Talker 生成首包和输出播放也有显著计算成本。

补充指标：在明确 GPU 型号和并发量（batch1）下测 `time per read`、RTF、first token latency、longest read/p95、decoder KV-cache reuse policy、峰值显存和吞吐；真实播放 lag 中计入这些成本并与 streaming cascade/LA2 在同一条件比较。单纯“只生成承诺的 token”不足以证明计算更便宜。

M18 [P1 / 证据缺失] 复杂语音场景的泛化边界和长期身份追踪仍不清楚

证据：Sortformer 最多 **8 slots**、约 80ms diarizer frames、K=5 个声学 token 插入一次 speaker token [v6 p.3, L191–246]；实验主要来自 AMI IHM-mix 和 AliMeeting 近讲式混音，未测远场；Limitations 亦承认这一点 [p.10 L754–759]。

问题：工业会议的说话人往往会离席又回来、音色随麦克风切换而变化、多轮连续无独说区域、存在 5–8 个甚至更多人；跨会议场景的 diarizer slot 身份漂移未用长时段曲线说明。已有 Table 1 的“meeting-level matching”可检测跨窗标签变化，但不能揭示 30/60 分钟内的身份错误时间分布。

建议：以 5 分钟为 bins 画 speaker slot drift、repeat-appearance accuracy、speaker count/overlap 负载；至少做近讲与远场/真实多设备模拟对照、≥5 speakers 的压力测试。明确超过 8 speakers 的预期行为：拒绝、合并还是动态扩容。

M19 [P1 / 证据缺失] 目标译文与声学 source 的对齐近似可能系统性污染同步训练

公式依据：Eq.(14) 用目标 chunk 的长度比例 `ϕ_j` 推断其覆盖源词的位置；En→Zh 使用 source word timing，Zh→En 则把同样比例线性映射到 utterance 时长；之后再加 **ε=1s** 得 deadline [v6 p.5, L350–368]。两语言的语序/信息密度不相同，短叹词、数字、否定常尤其不均匀。末读 `∪{R}` 强制 flush 使一部分 chunk 无法按单独 deadline 判断在线完成性。

新版本状态：新稿没有提供对齐时间误差或 target coverage 的独立实验；只继续用 AMI En→Zh 的 +9.90（相对 stable-prefix）归因于更准确的 deadline。[v6 p.9, L669–675；p.17 Table 15]

要求：报告 chunk deadline 与人工/可靠词级 alignment 的 MAE/p95，提前承诺需依赖未来词的占比，强制末读 flush 的 token/语句比例，ε 敏感性，标点和语言对重排的分层分析；给不同 source-to-target reorder 复杂度下的错误。尤其需要真实 Mandarin 或强制对齐改善后的 Zh→En 对照，不能用英语源有 alignment 的成功推出通用 read-target 优势。

M20 [P2 / 概念边界] 新标题更诚实，但“one model / one decoder”的强主张仍须限于文本联合生成

证据：Fig.1 的修订 caption 已明确 diarizer、encoder、Talker 不受联合翻译损失训练 [v6 p.3 L161–166]。方法真正联合生成的是带 speaker/time 的目标文本与 wait，另有冻结 diarizer、声纹片段截取、UniSS 外置语音生成和串行调度。新标题避免了 v5 的直接 `End-to-End S2ST` 定语，这是正面改进。与此同时 Abstract 仍有 “turns one omni-modal speech LLM into … interpreter”，Conclusion 仍写 “MIST makes one speech LLM a meeting interpreter”。[p.1 L009–019；p.9 L736–743]

建议：方法应明确 end-to-end 指的是“audio+speaker features→speaker-attributed target text/commit 的统一解码”，而非单一可联合训练 waveform-to-waveform model；将 speech synthesis/control 单独列为系统模块。对于 G-STAR 已提出的 interleaving，创新贡献应聚焦于 translation+timestamps+deadline+speech serving，而不是把 speaker token fusion 本身表述为首次提出。

M21 [P2 / 已确认] 表格与摘要关于文本/语音增益容易混淆

证据：Abstract 说离线在 AMI 优于 cascade `by 6.52 and 3.50 ... in text and in speech` [v6 p.1 L020–025]。实际上 6.52/3.50 是 **text cpBLEU**（Table 1）；Table 3 里语音 ASR-cpBLEU 对应 offline 增益是 En→Zh **32.69–31.06 = +1.63**，Zh→En **14.44–12.47 = +1.97**。[v6 pp.8–9, Tables 1, 3]

修订方式：抽象层面拆成两个句子，各自给 metric、source dataset、同数据 baseline 和差值；同时指出 “in whose voice” 并无普适跨语言验证。简单语言改动能显著避免审稿人怀疑夸大。

4. 逐公式、接口和评测逻辑核验

这部分不是宣称已经读取实现代码。它依据 PDF 公式找出**必须核验的可执行细节**，区别已确认的不一致与潜在实现风险。

位置	数学/实现含义	严格 reviewer 的核验点	状态
Eq.(1), p.2	`Y={(k_n,a_n,b_n,y_n)}`，`a_n<b_n`	是否容许空转写、极短回应、跨窗片段、重复 speakers?	定义清晰；与 Eq.(8) 零时长冲突
Eq.(2), p.3	`A=Enc(x)`，约 12.5 tokens/s	80ms 是 token 间隔还是严格因果 receptive field? prefix 重编码是否产生 token 漂移?	需实测
Eq.(3), p.3	`P=Diar(x)`，8 speaker slots	stream chunk 0.72/0.32/right context 与实际 1.04s frame finalization 怎么对应? session cache 是否仅过去?	新文字，验证缺席
Eq.(4), p.3	后验线性插值到音频 token 中心	边界处插值是否请求到尚未 finalized 的下一帧? padding 时是否归零?	需写测试
Eqs.(5)–(6), p.3	5-frame conv→MLP，约 6.3M projector	K=5 与 zero-init 效果是否消融? overlap posterior 与极短回应是否被平滑消去?	消融缺席
Eq.(7), pp.3–4	声学块与 speaker tokens 交错	Speaker stream 的位置编码是否与原模型预训练的 audio positions 冲突? 增加 20% token 的真实推理成本?	需解释
Eq.(8), p.4	`<spk><t_start>译文<t_end>`，251 time tokens	bin truncation、α=β(2.6%)、合法 token 约束和跨窗回填	存在确定问题
Eq.(9), p.4	以整会议参考标签 Hungarian 对齐 diarizer slots	仅用于训练/指标是合理的；测试推理不得依赖它；多人>8 的映射何如?	v6 已澄清输入边界
Eq.(10)–(11), p.4	加权 CE、LoRA rank32/α64	speaker/time 权重 2/1.5、perturb 0.2 的 ablations 与偏置	实验未报告
Eq.(12), p.4	`P^(r)` 将尚未结束 lookahead 的帧置零	只做 post-hoc mask 不能替代真正 prefix diarizer，需数值一致证明	声称验证却无表
Eq.(13), p.5	每次 greedy 继续直到 `<wait>/<eos>`，不可撤销	第一次读时 decoder 长度限制? 空读、格式不合法、后续矛盾 speaker label 如何纠错?	需边界策略
Eqs.(14)–(16), p.5	源词或时长按目标 chunk 长度比例给 deadline	语序重排误差、ε=1s、末读强制 flush、未对齐短句	核心训练偏差风险
Eq.(17), p.5	solo>0.5，other slots<0.5，≥0.4s 组成 voice prompt	首次 commitment 之前的 prompt coverage 和纯净度	缺实测
Eq.(18), p.5	单声道语音播放 `max` 递推	同时讲话队列增长、跨窗积压、输出时间顺序是否可靠	缺完整会议音频延迟
§ 3.9, pp.5–6	1s silence/20s 上限的在线窗口	实时关闭时刻、历史音频环形缓存、段落溢出、窗口连续边界	只有算法草图

位置	数学/实现含义	严格 reviewer 的核验点	状态
Eq.(19), p.13	meeting-level chrF speaker permutation	对长度悬殊 speakers、未匹配 slot、跨窗误标偏差的敏感性	合理主指标之一，但不含时间
Eq.(20), p.13	text LAAL 对序列长度作均匀时间线近似	并行 speaker 源与串行目标是否满足同一均匀参考时钟？需要 source-aligned lag	不能代替听众延迟
新 `tcpBLEU`, p.7	±2s collar 的时间约束译文匹配	单元匹配歧义、插入/遗漏计分、完整会议公式与实现	**指标定义和分数均未提供**

专门提醒：本文的 Eq.(9) 使用参考 speaker labels 来建立训练目标并不是违规；问题在于原论文需要明确区分 training oracle label construction、evaluation permutation matching 与 online inference feature. v6 正朝这个方向修订，审稿应承认改进，而非错误地指控它把 ground truth 作为测试模型输入。

---

5. 逐节、逐图与逐表复核（针对 v6 的 page-accurate 评论）

5.1 Abstract / Introduction / Related Work（pp.1–2）

- **摘要亮点**：确实把“说话人身份必须跨时间保持”“与传统级联不同”“commit 时必须先知道 speaker”说清楚了；在摘要中承认 AliMeeting 只持平尤其值得赞赏。[p.1 L001–036]
- **摘要仍应补边界**：把 `+6.52/+3.50 text cpBLEU` 与 `+1.63/+1.97 speech ASR-cpBLEU` 分别陈述；不要用 `in text and in speech` 模糊量级。明确 AMI Zh→En 的中文 source 是重配音，不是独立原生 Mandarin meeting。[p.1 L020–033]
- **Introduction 的贡献定位**：新标题把外部 diarizer/Talker 暴露出来是改进，但正文仍应解释“同一个 decoder 输出 who/when/what/commit”和“整个 speech system 不是全栈联合训练”的边界。[pp.1–2 L065–108]
- **Related Work**：作者正确引用 G-STAR 的 interleaving 来源，须在贡献表中用一行明确 G-STAR 已解决 global speaker tracking for ASR，本工作检验了 translation+timestamps+commit+voice；最好给直接从 G-STAR 初始化/adapter 的可控比较，避免仅列概念。[p.2 L133–152]

5.2 Figure 1、§3.2–§3.4（p.3, Eqs.(2)–(7)）

- **Figure 1**：总体链条现在明确显示 encoder、diarizer 为 frozen，speaker projector 与 Thinker LoRA 为 trainable，UniSS Talker 为单独外置模块；caption 新增梯度范围，是本版最有实质价值的写作改进。[p.3 Fig.1]
- **潜在逻辑落差**：Figure 1 对“read every Δ / write until wait”的算法看上去端到端，但真实逐 read 音频前缀重算、chunk 缓存、speaker projector 插值的可用时间没有 runtime 时序图。
- **需要的修订**：新增一张 0–5 秒的单窗 timeline，显示 `audio frame arrives→diarizer finalized→encoder prefix recomputed→Thinker emits speaker/time/text→Talker prompt ready→audio starts`。同时注明 TTS 可以在下一次 read 前后并发还是串行执行。
- **严重文内缺陷**：§3.3 的数值因果验证指向 `§??, Appendix ??`，属于提交前必须修的占位引用。[p.3 L215–218]

5.3 §3.5–§3.6（p.4, Eqs.(8)–(11)）

- **改进**：主动披露 floor time quantization 产生 **2.6% zero-length segments**，比原来完全不提更好。[p.4 L260–276]
- **但未解决**：Eq.(1) 明确 `a_n<b_n` 而输出 token 时间能 `α=β`，这不应在“正时长源片段”指标中静默通过。
- **参考对齐**：Eq.(9) 使用 full meeting reference Hungarian 计算监督 targets 可以接受；需要讲清测试对照的 oracle 是不可部署上界，与 online features 不应混同。

- **未做敏感度**：加权损失 speaker2/time1.5、LoRA rank32 和 P-noise p0.2 的效果无法在现有 Table 1 中被单独解释。[p.4 L298–316]

5.4 §3.7（p.4–5, Eqs.(12)–(16)）

- `η_R=<eos>` + deadline `∪{R}` 显示未读被用来保证所有剩余译文提交；对参考窗口来说 `R` 是由已知 `T` 决定。新的 §3.9 尝试解决 T 来源，但 **仍未测量新闭窗机制与旧结果差异**。[p.4 L325–333；p.5 L334–382]
- 改成 `x≤t` 音频前缀实时进入 encoder 是正确的因果实现意图；需要运行日志与至少一组数值等价检验，不能只给文字。
- 学习 deadline 的真实创新应以同训练预算的 prefix-LA2 / stable-prefix/fixed lag 证明；此类分数目前没有完整展示。
- Segment serialization 按源 start 排序，deadline 却按 end+ε；**重叠 speaker 可能先开始但后结束**，是否强制一个长 speaker 在 decoder 输出排序中阻塞另一个已准备好的短 backchannel？给出可用的 chunk due ordering 与口头短回复实例。

5.5 §3.8 Voice-prompted speech（p.5, Eqs.(17)–(18)）

- **外置 TTS 不等于错误设计**：系统工程中单独训练 Talker 是合理做法；需要准确命名贡献。
- **最大困难**：没有干净声纹 prompt 的新 speaker、0.4s 以内的 backchannel、首段恰逢 overlap 的情形。必须知道 prompt 何时建立，fallback 的 speaker mismatch 如何量化。
- **语音播放**：不同说话人串行导致的 backlog 不应只作为一句 scheduling 公式；这可能是整套系统用户体验的瓶颈。

5.6 新 §3.9 Running on a whole meeting（pp.5–6）

这节是与 v5 最大的方法差别之一。它使系统具备了**无需 reference utterance boundary 的推理规范雏形**：diarizer 激活开窗、1s silence 或 20s 结束、声音提示因果构造、跨窗保持 speaker slots 与播放 queue。[L406–434]

但不能把“方法新定义”写成“实验已证明”。请提供 end-of-window 的真实检测时间线、源音频 ring buffer 与 speaker cache 细节、TTS queue 跨窗的更新算法，尤其是硬切 20s 与最后补 0.3s 的处理；并给真实整会议量化结果。若 §3.9 只是 proposed deployment mode，请明确说其未验证；若已经测过，请在 §5 新增整节而非仅在 §4 预告。

5.7 Experimental Setup（pp.6–7）

- **数据披露进步明显**：新覆盖率 45.6%/35.6%（英中）与 63.0%（真实 Mandarin）应从文字提升为独立 coverage table，并明确“总会议时间、speech 秒数、overlap 秒数、保留 speech 秒数”的分母。[p.6 L436–503]
- **基线列举丰富，但无 score**：将 training-turn、oracle-turn、contextual turns、post-hoc stream、LA2-on-Simul、fixed lag 和 streaming cascade 全部在表格列出效果，至少让主评审能定位最佳非 oracle baseline。[p.7 L525–566]
- **附录与新统计不一致**：Bootstrap 1000 次、two-sided、permutation、Holm、pre-registration、LOMO 全部必须以同一显著性分析表支持；目前 Appendix F 没跟上。[p.7 L608–617；p.13 Appendix F]
- **不应将两个方向当作独立外部验证**：它们共享 AMI 原始会议，v6 已正确指出这一点，仍需要在 Discussion 中解释二者相互关联。[p.6 L478–480]

5.8 Table 1（p.8）：最强窗口级文本证据与不充分的比较

- 同数据 cascade vs MIST offline：En→Zh **36.29→42.81**；Zh→En **22.36→25.86**，明确显著，有价值。
- LA2 vs learned wait：En→Zh **31.64→42.63**，差距大，但 LA2 没进行 prefix 训练、输出长 1.18×；无法隔离 policy 贡献。
- Zh→En learned wait **24.30** 低于 LA2 **24.81**，且 **2.93>2.50s**，应在摘要里单列消极结果而不是把双向混为一谈。

- **表中没有 v6 新增的 3 类 cascade、post-hoc、prefix-trained LA2 等任何一行**。既然文字已定义，缺表是核心实验完整性问题。

5.9 Table 2（p.9）：最接近真实场景的结果未证明架构改进

- AliMeeting 是 **真实中文会话声学**，虽 close-mic 混音但比合成中文 AMI 更有外部效度。
- offline cascade 在 cpBLEU **15.25**、spk **92.5%**、DER **13.1%** 都略高/低误差于 offline MIST **14.90**、**91.9%**、**14.7%**。
- simultaneous 的 +0.87 差异不显著、text LAAL 反而晚 0.25s；本表应被主叙述放在“零样本边界”而非应用成功的辅助证明。
- 新版宣称整会议/不筛选后，真实 Mandarin 的新结果最关键，但**完全没给**。

5.10 Table 3（p.9）：只能证明 ASR 转录的译声质量，不足以证明“each in their own voice”

- En→Zh offline **cpASR 32.69 vs cascade 31.06**，Zh→En **14.44 vs 12.47**，语音路径有一定质量增益，但大小不同于 text BLEU。
- En→Zh MIST SIM **0.82** 与 cascade **0.82** 一样；Zh→En MIST SIM **0.69** 低于 cascade **0.73**；对应 V-conf 更差 **60.2% vs 47.2%**。
- v6 声称增加 TitaNet 第二 verification 模型，但 Table 3 仍只有单一 SIM 列，caption 指向 WavLM；必须报告第二模型的分数与计算负例的范围。
- UTMOS 和 ASR 错读率不能代替真实参会者“这是谁的声音/是否可懂”的人评。

5.11 Table 4 / Table 5（pp.12–13）：数据与训练超参数

- Table 4 的 2,375/3,317/4,243 窗口数据没有显示新披露的 **原始 speech coverage**、overlap coverage、短 backchannel coverage。建议在同一张表加列，避免读者把 `multi%` 误解为持续时间覆盖率。
- 同一 16 个 AMI 测试会议承载两语言方向，v6 已写明；不要汇总当作 32 independent meetings 做推断。
- Table 5 提供学习率、LoRA、噪声、train rows 和 8H200，适合复现训练；对**推理**硬件、峰值显存/latency、batch1 仍没有数据。

5.12 Figure 2 / Table 6（p.14）：延迟质量曲线与 0.5s 自适应

- 原始 MIST-Simul 测试在 `Δ=0.5s` 时 En→Zh `cpBLEU=23.31`，Zh→En `5.89`，这是严重退化；混合-Δ 训练在 En→Zh `42.79 @2.18s` 能恢复质量，但不是“实现 0.5s 听众端延迟”。
- En→Zh 在 `Δ=2s` 的 MIST-Simul `40.66` vs offline+LA2 `37.29`，仅 +3.37，Table 9 meeting p=0.076（旧单侧定义），不能声称稳健显著领先。
- Figure 2 横轴画到 20s，绝大多数关键点拥挤在 0–4s；请提供 0–4s 局部放大和 meeting CI，并把 text-LAAL 与 listener-side completion-lag 分开画。
- Table 6 对 Zh→En `Δ=0.5s` 说明部分窗口因显存问题降低 batch size，建议描述完整 realtime 实测限制，不能直接把离线 batch 解码速度当线上推断性能。

5.13 Tables 7–8（p.15）：归属与翻译的非平凡解耦

- En→Zh 去 stream 模型 `cpBLEU_win=42.32` 接近 MIST `42.97`，但 session-level 分数 **21.17 vs 42.81**：是跨窗 identity 的强证据，**却不是 interleaving 结构独有贡献的证明**。
- Zh→En oracle speaker posterior 使 `cpBLEU_sess` 从 25.86 到 27.32，证实该方向 diarizer 仍是瓶颈的一部分；En→Zh oracle 42.81→42.32 反而略降，需解释 oracle stream 与训练 posterior 分布差异。
- cpchrF_sess 与 cpBLEU_sess 反映不同聚合/惩罚，在论文中应解释为什么 BLEU 的大差值在 chrF 上可能很小，而不是只选最有利指标。

5.14 Table 9（p.15）：显著性表不符合本版新增的统计方法声明

- 原 caption 定义的是 1000 bootstrap 的 “first system is not better” 概率，并列 windows/meetings CI/p；**没有两侧 permutation、Holm-adjusted p、LOMO 或 seed variance**。
- 部分 `p<0.05` 对应 95% CI 穿过 0（详见 M05）。这可以来自单侧 p 与双侧 CI 混用，但与 v6 的统一“two-sided”声明相冲突。
- 若 v6 的 Holm family 包含多项新增比较，不能在不明确比较家族与原始 p 的条件下推断以前星号仍全部成立。请重算并更新 Table 1 † 与正文所有 “significant” 文案。

5.15 Table 10 / Table 12（p.16）：多人场景的困难没有被总分充分呈现

- **必须讨论**：En→Zh multi-speaker speaker-count accuracy MIST offline **72.8%** vs cascade **78.7%**，虽然 multi cpBLEU 更高；这是一个真正有信息量、同时包含优点与局限的结果。[Table 10]
- MIST-Simul 相比 offline MIST 在多人的 `under-count` 改善（En→Zh 21.1% vs 25.9%），但 `Wrong` 10.9%→14.3%，`Insert` 4.2%→5.9%；不能说所有维度都改善。[Table 12]
- Table 12 没纳入 same-data cascade，无法与最强非 oracle baseline 在相同实例级归属误差 taxonomy 下直接比较。
- Start error 为预测时间戳对 reference 的误差，不等于目标音频实际开始/听到的延迟；必须改清楚字段名称。

5.16 Table 11（p.16）、Tables 13–15（p.17）

- **Table 11**：重新用 diarizer cut 的 871 个窗口验证 offline MIST 43.36 vs cascade 37.53，很有帮助，但 **871/2,375≈36.7%**，且仅 En→Zh、只保留完整 utterances；这仍不同于 unfiltered whole-meeting simultaneous。
- **Table 13**：一个有说服力的 `yes` overlap 错分案例，但应扩充为有可复核抽样规则的定量错误标注集，而不是由单例主导机制解释。
- **Table 14**：合成中文源审核删除 19,081/123,353 utterances（约 15.5%），与最困难的短 backchannels 有关；应报告原时长与具体 speaker/overlap 分布，不可简单认为过滤不影响难度。
- **Table 15**：deadline vs stable-prefix 的 En→Zh `42.63 vs 32.73` 是重要观察，但本版新增“同窗同读”声称没有体现在 Appendix J 的实验定义中；要求清楚区分 full-data 与 matched-data 结果及计算预算。

6. 次要与工程可复现问题（25 项可执行意见）

ID	问题（证据）	要求的最小改进
T01	`§??` / `Appendix ??` 未解析 [p.3 L218; p.6 L459; p.7 L589]	重新编译后全文搜索 `??`、缺失引用和表格占位。
T02	§3.9 使用 20s 硬切，时间词表也只到 20s [p.4 Eq.(8); p.5 §3.9]	报告跨窗绝对时间 offset、边界强行切句数。
T03	参考 speaker→slot 采用全会议 Hungarian [p.4 Eq.(9)]	加注“target construction / evaluation only”，并公开 inference trace 验证。
T04	一条 decoder 输出按源起点排序，due-time 可不同 [p.4 Eq.(8); p.5 Eq.(16)]	分析 overlap 导致的 head-of-line blocking 与短 backchannel 延误。
T05	Speaker posterior 使用阈值 0.5、±frame shift/noise [p.3 Eq.(3); p.4 L313–315]	报告 0.3/0.5/0.7 threshold 灵敏度，尤其低音量会议。

ID	问题（证据）	要求的最小改进
T06	K=5 acoustic tokens/one speaker token [p.3 Eq.(7)]	做 K=1/2/5/10 与 additive / prefix-only fusion 对照。
T07	Speaker token loss2、time1.5 [p.4 Eq.(11)]	加 weighted-loss ablation：归属/翻译/时间三指标。
T08	LoRA 更新 Q/K/V/O 全 48 层 [p.4 L305–312]	给 trainable parameter count、每个方向训练 token 数和推理消耗。
T09	`α=β` 2.6% 被保留 [p.4 L272–276]	加最小时长约束并分别评测短段。
T10	末读 `η_R=eos` 的特殊规则 [p.5 Eq.(13)]	统计末读一次性 flush 的 chunk 和延迟比例。
T11	`1s silence` 的闭窗依赖 low-latency diarizer [p.5–6 § 3.9]	报告真实 close detection latency，不要用源内 silence 开始时刻冒充可知时刻。
T12	`0.2s pre-pad/0.3s post-pad` 可能跨窗重复 [§ 3.9]	说明 overlap chunk dedup 和时间戳绝对定位。
T13	未明确 decoder KV-cache 是否每 read 可用 [§ 3.7]	给缓存失效/重算策略和 batch1 实际运行时间。
T14	单通道 TTS 一次仅能播一段 [Eq.(18)]	给 queue backlog 曲线、spillover 和会议结束额外播放时间。
T15	首次 voice prompt 可能尚无 0.4s solo [Eq.(17)]	报告 prompt-ready rate 与 fallback 语音混叠率。
T16	V-conf 与 SIM 是否只统计 multi-speaker window? [Table 3]	明确 negative speaker sampling 单位（window/meeting）。
T17	新提 TitaNet 但未列独立分数 [p.7 L605–607]	WavLM/TitaNet per-language 结果和 CI。
T18	UTMOS/ASR quality 不能替代人评 [Table 3]	给听众盲测，尤其 Zh→En voice identity。
T19	AliMeeting 的英文参考为 MT，未人工核验 [p.6 L488–503]	对随机和困难样本双语审查，给质量/术语统计。
T20	Overlap 论文任务重心，却只给窗口比例与少数错误例 [Table 4/12]	按实际 overlap ratio 与 duration 报告检测/归属/翻译，区分同时讲话对数。
T21	Session BLEU 映射使用 chrF，时间信息独立 [Eq.(19)]	公开 speaker permutation、partial-map 和空句计分代码。
T22	新 `tcpBLEU` collar=2s [p.7 L579–589]	证明对 ≤1s backchannel 不过宽；做 collar 0/0.5/1/2s ablation。
T23	单一随机种子与 extra seeds 描述矛盾 [p.7; p.10]	修正 Limitations 并列出所有 model×seed。
T24	Figure 2 x轴画到20s，但数据集中在0–4s [p.14]	提供缩放图、配 meeting CI 和真实音频 lag。
T25	Related Work 涉及其他 multi-talker ASR/S2ST，但系统对比只在自建任务内 [p.2]	给任务差异表；如不可同评，说明为不可比而非遗漏。

7. TeX 源文件专项审计：这次实际能验证什么？

7.1 文件范围与是否可重编译

提供的 `gs_v6.tex` 是 **60 行主入口文件**，而不是包含公式/实验正文的自足源码。它使用如下外部依赖：[gs_v6.tex:L33–34、L47–58]

```
\input{generated/macros}
\input{generated/macros_v6}
\input{sections/abstract}
\input{sections/introduction}
\input{sections/related}
\input{sections/method}
\input{sections/setup}
\input{sections/results}
\input{sections/conclusion}
\bibliography{references}
\input{sections/appendix}
```

本次上传未包含上述 `generated/`、`sections/` 以及 `references.bib` 和表格生成脚本。因此，**不能**基于目前附件验证正文 `.tex` 的 `\label/\ref` 是否写对、对公式逐行审代码、追踪 macro 展开后的表格来源、重复运行 `tectonic` 或确认作者本地源码能否正确编译。应评价为“**提供的附件不足以执行源码审计**”，而不是无证据地断言“作者的完整项目缺失或代码不可复现”。PDF 本身能对实际编译结果进行严格文本核查。

7.2 v5→v6 主文件的真实 diff

1. **Title**：[L39–40] 从 “End-to-End … Speech-to-Speech Translation of Meetings” 改为 “Diarizer-Conditioned … Voice-Prompted Speech”。这是正确且应保留的定位修订。
2. **新宏文件依赖**：[L34] 新增 `\input{generated/macros_v6}`；但它的内容没有上传，因此无法核验新数字或 `§??` 是否从生成宏输出。
3. **字体移植性**：[L31] v5 使用固定文件路径加载 `DroidSansFallbackFull.ttf`，v6 改为 fontconfig family `Droid Sans Fallback`，**比机器绝对路径更便携**；但目标编译环境需安装匹配 family/提供可用替代，建议同时给 font fallback 与构建依赖清单。
4. **构建脚本说明**：[L2] 改为 `tectonic main.tex` 并先后运行 `scripts/make_tables.py` 与 `scripts/make_tables_v6.py`；上传文件实际名是 `gs_v6.tex`。这不必然表示构建错误（主仓库可能将它命名为 `main.tex`），但作者需要给可以复现实验表和 PDF 的完整项目结构、命令、依赖版本以及输出核对哈希。
5. **字号/版式**：[L3–23] 使用 `\documentclass[11pt]{article}`、`\usepackage[review]{acl}`、XeLaTeX 生态的 fontspec；版式视觉正常。`fontspec` 与传统 `fontenc/inputenc/times` 混用可能影响可移植性，但本次 PDF 已生成，不能直接当作已发生的构建故障。
6. **匿名化**：[L42] `\author{Anonymous ACL submission}`，符合匿名审稿稿件的形式目标；没有查看其编译环境及隐藏 metadata 的完整源文件，无法对所有匿名性风险做保证。

7.3 提交前应自动运行的 TeX / PDF 审计

- 对整个项目全文搜索 `??`、`TODO`、`TBD`、`Appendix ??`、`§??`、未填充结果宏与重复 `\label`；重点处理 PDF p.3 L218、p.6 L459、p.7 L589。
- 编译干净目录两次，检查 `undefined references`、missing bibliography entries、overfull boxes 和 PDF 文本抽取后的表格数据；生成 PDF 与本次“v6 tables”中的指标保持一致。
- 检查新 `macros_v6` 的所有宏确实在 `sections/results` 与 Appendix 新结果表里被调用，防止生成了数据却正文仍然包含旧版表格。

- 将正文“已训练额外 seeds、已跑整会议”与 `results` 实际呈现严格一一对应；在 `Limitations` 中同步修改，不要留下显式否定句。
- **可能存在的版面合规问题**：新稿第 9 页才结束 Conclusion，第 10 页开始 Limitations/References。不同目标 ACL 会议/track 的主文页数规定不同；应按**实际投稿 venue 当年规则**核验，不应在未核实规则时认定已超页。

8. 必要补充实验与重写优先级：按投入产出排序

P0-A｜交付完整会议总表（最重要，决定是否有真实部署证据）

数据：AMI 官方 test 16 meetings、AliMeeting 20 meetings 的原始完整音频；可再报告 revoiced Zh→En，但必须与真实中文声学分开。**系统**：MIST offline→online、streaming cascade、turn-trained cascade、LA2 on prefix-trained MIST，使用严格一致的 diarizer/lookahead/voice prompt/Talker/硬件条件。**主表列**：coverage（原始语音）、speaker-attributed `tcpBLEU`、`cpBLEU_sess`、DER、speaker-count、omission/duplicate、text commit lag、audio onset/complete lag p50/p90/p95、peak backlog、RTF。全部不使用人工参考边界决策。

P0-B｜提交 baseline 公平性矩阵（新稿已经提出，必须完成）

对照	为何重要	需要对齐的条件
Turn-trained cascade	消除 train-on-window/test-on-turn 失配	同训练原始会议、同语音总量、相同转写/MT 目标
±2s contextual cascade	隔离“完整上下文可见”收益	overlap 注入机制及相同 commit/延迟计量
Oracle-turn cascade	估计切分/身份误差的上界	只作 oracle 上界，不与在线模型宣称公平
Post-hoc relabelling	证明 interleaving 不只是携带 slot ID	相同 P、相同 speaker permutation 规则
LA2 on MIST-Simul checkpoint	区分 prefix-training 与 wait policy 收益	同 checkpoint、前缀可见信息、read interval
Fixed lag on MIST-Simul	检查 learned wait 是否必要	匹配质量/延迟 Pareto 前沿
Streaming cascade	对齐可部署场景	相同窗口起止、同低延迟 diarizer 和 Talker

P0-C｜彻底重做统计结果与 seed 报告

主结果按 meeting 作为 cluster：展示各 meeting 的 per-system 差值点图、cluster bootstrap CI、two-sided paired permutation p、Holm-adjusted p、预设 comparison family；重要模型至少 3 seeds 的 mean±SD；对 AliMeeting 持平与 En→Zh 主胜利都做 LOMO，提供原始 / 调整后的 p。若新“预注册”其实只是提交前选定检验而没有可核验时间记录，保守称 `pre-specified comparisons in this version` 而不是 `pre-registered`。

P0-D｜严格在线因果与时钟校验

输出一段单会议真实时间 trace：每次 `t_r`、音频前缀采样数、diarizer finalized frames、slot ID、projector token count、decoder text chunks、`wait/eos`、Talker prompt可用时间、TTS开始/完成时间和播放 queue 变化。验证 per-prefix audio/diarizer 的输出独立于后续数据，并报告任何差异。把这一 trace 的聚合数值写进正文或 Appendix，替换 `§??`。

P1-A｜补声音身份与感知的人评/双 speaker verifier

至少随机抽样覆盖 2–4 人、短 backchannel、早期第一个 utterance、严重 overlap、无 solo prompt、En→Zh 与 Zh→En。报告 voice ID（forced choice/ABX）、原声 speaker↔合成 voice 对应、MOS、可懂度、英中跨语种 speaker embeddings 的校准；TitaNet 与 WavLM 分开给表。

P1-B｜补 domain / filter bias / short-overlap 压力测试

在保留与未保留的原始 speech 上测试是否被识别/归属，按短句、interruption、长段、纯 overlap 的比例和性能报告；AliMeeting 至少 63% speech 覆盖与全量结果并列，不要把异质分母下的得分当作可比改进。

P1-C｜完成 matched-read-target 与 timestamp 修复

8k-window deadline vs 同 8k stable-prefix、全训练集 deadline 与单独增强对比，匹配 read interval / token budgets；将零时长时间片修复后重新评测 DER，做 cpBLEU/tcpBLEU/collar/endpoint 共同分析。

P2｜无需重新训练的文字/制作修改

清理 PDF 未解析引用；同步 Limitations、§5 与新增 §3.9；在 Abstract 拆分文本/语音增益，重画 Figure 2 的 0–4s 轴；让 Table 4 含 speech/overlap coverage；明确单方向与双向共用 AMI meetings；将过度概括“speaker-count more often”改为分 single/multi 条件的结果。

---

9. 我希望在 rebuttal 中得到的 18 个明确答复

1. 新 §3.9 在 **16 个完整 AMI 与 20 个完整 AliMeeting** 上是否真的运行过？若运行了，请给实际完整会议数值；否则请解释 §4 新措辞与 Limitations 的冲突。
2. 当前 PDF 中 `§??` 与 `Appendix ??` 所指的**确切表/段落**是什么？为何没有出现在编译结果？
3. 新列的 turn-trained/contextual/oracle cascades 的 cpBLEU、tcpBLEU、DER、在线完成 lag 各是多少？尤其最强非 oracle baseline 是哪一个？
4. Post-hoc relabelling 的 `cpBLEU_sess / cpBLEU_win / DER` 是多少？与 interleaving 的差异在 multi-speaker windows 上显著吗？
5. `MIST-Simul+LA2` 和同 checkpoint 的 fixed-lag 模型实际结果是什么？它们是否推翻或显著缩小 +10.99 的解释？
6. 同 8k windows/read 配置下 deadline vs stable-prefix 的 matched-data 结果是多少？它是否确实对应 Table 15？
7. 完整会议语音 `p50/p90/p95 completion lag`、最坏积压时长、RTF 和 speaker switch 各是多少？目标语音是否在源会议结束后还播很久？
8. Prefix-only diarizer 与整段 streaming diarizer 对有效帧 posterior 的数值最大差异、slot 分配不一致率和同一 speaker 再次出现后的缓存漂移率是多少？
9. 音频 encoder 在不断加长前缀时，已生成 audio embeddings 是否变化？每次 read 是否完整重算、是否有 KV-cache，batch1 GPU 上真实耗时多少？
10. En→Zh 的 **multi-speaker speaker-count 72.8%** 为什么低于 cascade 的 **78.7%**，而总体指标更好？主要错在哪个 speaker/overlap 时长区间？
11. 45.6% En→Zh retained speech / 35.6% retained overlap 的样本是否能代表完整会议？丢弃窗口对 MIST 和级联的相对排名会怎样改变？
12. 2.6% 的 `α=β` 零时长 segment 中，有多少是短 backchannel，若修正为最短 1 bin，DER 和 tcpBLEU 是否改变？
13. 首次 commit 前没有 ⩾0.4s solo voice prompt 的 speakers 占多少？fallback 是否包含多说话人混音？

14. 新提到的 TitaNet 结果在哪张表？与 WavLM 是否一致？Zh→En 的 voice confusion >50% 要怎样理解“in their own voice”？
15. 新的 tcpBLEU 对多段-多 unit 的冲突怎么解决？是否能给算法和 2s collar 敏感性？
16. 何为 **two-sided** p？Table 9 的 p caption 明确写 one-sided bootstrap tail，并存在 95% CI 过零而 p<0.05 的行。哪套数值是提交版的有效结论？
17. 声称 En→Zh 又训练两颗 seeds：三个具体 checkpoint 的质量/延迟/失败率、平均和方差分别是多少？Limitations 为何仍称 single seed?
18. 下一版的核心贡献应该定义为“更高的**完整会议在线可听**归属质量”，还是“在有参考窗口时的归属译文质量”？请基于实际数据选择一致的主张。

---

10. 作者应保留的优点（不能因为严苛审稿而忽视）

1. **真实任务重要**：以“谁说什么，何时说、用谁的声纹输出”定义同步会议翻译，明显超出了传统单说话人 S2ST，尤其重叠和 backchannels 的语用意义很强。[§ 1]
2. **融合思路合理**：让冻结的长期 speaker cache 负责 identity 记忆，而 Thinker 负责短时多说话人翻译，避免 diarizer turn 的 hard split 误差；可解释性比简单串联更好。[§ 3, Fig.1]
3. **AMI 的对照数字确有意义**：在同数据 translator 级联基线上，离线 cpBLEU_sess 的 +6.52/+3.50 有明确得分差，且语音 ASR-cpBLEU 同方向上升。[Tables 1,3]
4. **技术细节相对丰富**：token/fusion/weighted loss/soft speaker stream/label mapping/commit supervision 写得具体，附录补充错误示例与超参数。[Eqs.(2)–(20)]
5. **新版标题和限制披露更审慎**：承认 speaker interleaving 来自 G-STAR，说明 Talker 独立训练，说明 real Mandarin 没有优于 cascade；新增覆盖率 45.6%/35.6% 是诚实且有帮助的科学披露。
6. **新 baseline 设计方向正确**：turn-trained、post-hoc、prefix-trained LA2 与 full-meeting lag 正是社区会要求的实验；从研究计划看已找到应对上一轮 review 的正确问题，只差实际证据与一致性。

---

11. 给 Area Chair 的精简判断与条件式结论

目前不足以因为 v6 增写了整会议评测段落而提高打分。 原有的窗口级 AMI 数字在方法层面确实有价值，论文无须被批为“完全缺乏创新”。但新增的最关键实验（完整会议、可信 realtime listener latency、公平在线基线、跨 seed 统计）**没有任何可引用的结果表**，且 § 4/ § 3.9 和旧 Limitations 直接冲突，`§ ??` 明显未定稿。这种结果与声明脱节比单纯“还应多测一个数据集”更严重：当前提交的科学主张无法由当前提交的科学证据独立检验。真实 Mandarin 上没有显著更好、短重叠样本被严重过滤、En→Zh multi-speaker speaker count 低于 cascade，也都应限制泛化措辞。

建议模拟结论：Weak Reject（2/5，confidence 4/5）；如果版面限制使整会议结果无法出现，我更倾向于将文章重新定位为“speaker-attributed translation in reference-segmented AMI windows”，缩小线上声学结论，而不是继续宣称完整会议部署。反过来，若作者补入已完成的新对照表且结果支持当前主张，这些缺口是可以转化为强贡献的。

Appendix A — Ready-to-adapt English ACL/ARR-style review

Summary

This submission studies speaker-attributed simultaneous speech-to-speech meeting interpretation. It combines frozen Qwen3-Omni acoustic representations with the activity posteriors of a frozen streaming Sortformer, inserts learned speaker-activity tokens among acoustic tokens, and trains a unified Thinker decoder to emit speaker-attributed, timestamped translations and a `wait` token. A separately trained UniSS Talker converts translated segments into voice-prompted speech. The paper reports substantial speaker-attributed text translation gains over a same-data diarization-then-translation cascade on reference-segmented AMI windows (+6.52 cpBLEU for En→Zh and +3.50 for revoiced Zh→En). Its learned commit policy substantially outperforms LA2 applied to the offline model on En→Zh, but not Zh→En. On real Mandarin AliMeeting, the offline model does not outperform the same-data cascade.

Strengths

1. The problem is timely and practically relevant: an interpreter needs to convey speaker identity, translation content, and approximate timing under overlapping speech.
2. The division of labor between an external long-term speaker tracker and a speech LLM capable of short-window translation is a plausible and interesting system design.
3. The format that jointly emits speaker, timestamps, target-language text, and `wait` is technically specific and potentially useful beyond the present application.
4. The same-data cascade comparison, session-level speaker-aware evaluation, and extensive AMI analysis provide informative evidence that the approach is effective under the reported reference-window conditions.
5. This revision improves the framing by changing the title to “Diarizer-Conditioned” and explicitly describing the separate frozen diarizer/encoder and externally trained Talker. It also discloses strong data-selection limitations and correctly notes that both AMI directions use the same underlying meetings.

Major weaknesses

W1. The new evaluation protocol and the reported results are inconsistent. The revision introduces a whole-meeting online-window algorithm (§ 3.9), complete-meeting `tcpBLEU` and listener-side playback lag, stronger cascade/online baselines, extra En→Zh seeds, and two-sided permutation/Holm-corrected tests (§ 4). However, none of the new whole-meeting results, new baseline scores, seed summaries, or time-constrained metric scores appears in the presented tables. The Limitations section still explicitly states that whole meetings have not been evaluated end to end and that listener-side lag is measured within windows. Consequently, the strongest new claims cannot be evaluated from the submitted PDF.

W2. The key comparisons remain confounded. The +10.99 En→Zh simultaneous gain is relative to LA2 on a model trained on complete windows, which the paper itself reports as degenerate under partial input. The revision now defines LA2 on the prefix-trained model, fixed-lag controls, and a streaming cascade, but provides no results. Similarly, a same-data translator that is trained on multi-speaker windows and applied to diarization turns is not equivalent to a turn-trained cascade; the newly described turn-trained, contextual, and oracle-turn baselines are not scored. The newly described post-hoc relabelling baseline is essential for determining whether interleaving is better than supplying the same persistent diarizer identities after decoding, but it is also missing.

W3. The new statistical claims do not match the appendix. The experimental setup states that p values are two-sided and selected tests are Holm-corrected. Appendix F and Table 9 still describe a bootstrap tail probability defined as the fraction of resamples in which the first system is not better. Some reported p values below 0.05 are accompanied by 95% confidence intervals that include zero, which is consistent with mixing one-sided tail

probabilities and two-sided intervals, not with the current uniform two-sided claim. There is no revised permutation-test table, adjusted p-value table, leave-one-meeting-out result, or summary of the additional training seeds. The paper must specify one coherent inferential procedure and update the numerical results.

W4. End-to-end streaming validity and audio latency remain unverified in the document. The new causal-streaming description is more precise than before, but its claim of a numerical prefix-equivalence check points to unresolved placeholders (“§ ??, Appendix ??”). The whole-meeting algorithm is described without results. Text LAAL does not include decoding, TTS, or serial single-channel speech playback. Equation (18) implies that overlapping target speech can accumulate as a queue across the meeting. Without complete-session listener-side onset/completion-lag distributions, backlog growth, and real-time-factor measurements, the paper cannot establish usable low-latency speech-to-speech behavior.

W5. The evidence is sensitive to filtering and domain shift. The revision discloses that the principal En→Zh reference-window test retains only 45.6% of the original speech and 35.6% of overlapped speech, while the AliMeeting windows retain 63.0% of speech. This is particularly consequential because short, overlapping back-channels are a major error mode. On real Mandarin meetings, MIST does not outperform the same-data cascade offline. The revoiced AMI Mandarin input is synthetic and is not independent of the English AMI meetings. These limitations substantially constrain the generality of the claims.

W6. Speaker and voice attribution require more nuanced treatment. In the most relevant En→Zh multi-speaker subset, the offline MIST speaker-count accuracy is 72.8%, below the same-data cascade’ s 78.7%, despite higher cpBLEU. This distinction is not adequately discussed. The revision also reports 2.6% zero-duration segments after timestamp quantization, despite the task requiring positive-duration spans. Speech evaluation relies on ASR and speaker embeddings, without a listening study; Zh→En voice similarity/confusion are worse than the cascade’ s. The newly mentioned TitaNet results are absent from the speech table.

Questions for the authors

1. Have the proposed whole-meeting online experiments been run? If yes, where are the text, speech, latency, backlog, and error-rate results, and why does the Limitations section still say that they have not been evaluated?
2. What are the actual scores of the new turn-trained/contextual/oracle cascades, post-hoc relabelling, LA2-on-Simul, fixed-lag, and streaming-cascade controls?
3. Can the authors provide the claimed numerical causality check, specifying the maximum posterior discrepancy and any speaker-slot changes between true-prefix and streaming inference?
4. How are the two-sided tests and Holm adjustment computed? Which Table 9 values correspond to permutation p values, adjusted p values, and the published confidence intervals?
5. What are the three En→Zh seeds’ individual scores, and why does the Limitations section continue to describe single-seed training?
6. What are the complete-meeting audio completion lag, p95 queue backlog, model/TTS real-time factor, and speaker prompt availability at first commitment?
7. Why is multi-speaker speaker-count accuracy lower than the cascade on En→Zh, despite a higher speaker-attributed BLEU score?
8. How are zero-duration timestamp segments, 20-second forced splits, and the new `tcpBLEU` reference-unit collisions handled?

Recommendation

Weak Reject; confidence 4/5 (simulated). The technical direction and the reported reference-window AMI gains are promising, and the revision identifies several important evaluation deficiencies. Nevertheless, the submitted PDF contains new proposed evaluation machinery without the corresponding empirical results, several explicit contradictions between setup and limitations, and unresolved cross-references. The current evidence does not yet support the strongest whole-meeting, causal-real-time, and voice-preservation claims. My assessment would be substantially more favorable if the authors supplied the new matched baselines, continuous-meeting results and listener-side speech latency, verified the causal implementation, and reconciled the statistical tests.

Appendix B — 文件和证据完整性清单

- 阅读材料：17 页 `gstar_v6.pdf`（逐页渲染检查正文、Fig.1、Fig.2 与 Tables 1–15）；`gs_v6.tex` 主入口 60 行；旧 v5 PDF/TeX 仅用于确认哪些改动属于本次修订。
- 非本次完成的任务：未取得 `sections/`、`generated/`、bib、模型 checkpoints、推理代码、音频数据、实验日志或逐字翻译参考，故**没有重跑系统，也没有复算训练 checkpoint 或 significance p-value**。所有差值来自论文可见数字的算术核对。
- 可信性分级：“已确认” 只指原文有明确的相互矛盾/缺表/数值；“需要验证” 包括是否真正未来泄漏、是否真实时间跟不上、是否全部声纹 prompt 被污染等，**不能当作作者代码已被证明错误**。
- 阅读/生成提示：PDF 中的页边 L 号是论文印刷行号，可能与提取文本的字节行号不同；建议在准备 rebuttal 时统一按 `p. / L. / Table / Eq.` 逐条定位。

最后的原则：严苛审稿应该奖励实质补强、准确识别证据不足，而不是把“没有看到证明”偷换成“已证明系统作假”。本报告的最高优先级是让作者把 v6 已新增的实验计划变成**可被其他研究者独立阅读、对比和复核的真实实验结果**。